

Compressão de índices vetoriais em português brasileiro: quanto custa economizar memória em sistemas de recuperação semântica

Proposta técnica, com metodologia, limitações declaradas e restrições de prazo e custo.

Autor: Rafael Marins Florenzano · Engenharia de Computação, UNIFOR · Agosto de 2026 · Versão 1

1. Pergunta de pesquisa

Até que ponto é possível comprimir a representação vetorial de um índice de recuperação em português brasileiro antes que a qualidade da busca se degrade de forma mensurável, e qual é a taxa de troca entre memória economizada e qualidade perdida?

2. Contexto e lacuna

Sistemas de busca semântica e arquiteturas de RAG (Retrieval-Augmented Generation) representam cada trecho de documento como um vetor denso de alta dimensionalidade. Em produção, o custo dominante não é o treinamento nem a inferência do gerador, e sim a memória necessária para manter esse índice residente. Um índice de um milhão de trechos com o modelo BGE-M3, cuja representação densa tem 1024 dimensões em precisão simples, ocupa aproximadamente 4,1 GB apenas de vetores.

Bancos vetoriais como o Qdrant oferecem quantização escalar (int8) e binária como mecanismos padrão de redução desse custo, com fatores nominais de 4 e 32 vezes respectivamente. A decisão de adotá-las, porém, é habitualmente tomada com base em curvas de degradação medidas sobre benchmarks em inglês, sobretudo MTEB e BEIR. A hipótese implícita de que essas curvas transferem para o português nunca foi verificada publicamente, apesar de sustentar decisões concretas de infraestrutura em qualquer organização brasileira que opere busca semântica.

A lacuna existe porque, até recentemente, faltava um conjunto de avaliação de recuperação nativo em português. Datasets traduzidos como o mMARCO e o mRobust04 mitigaram parcialmente o problema, mas a tradução automática descaracteriza traços socioculturais da língua-alvo e envies a avaliação na direção da língua de origem. Esse gargalo foi endereçado pelo Quati, descrito na seção 3.1.

3. Metodologia

3.1 Conjunto de avaliação

Será utilizado o **Quati** (Bueno et al., STIL 2024), conjunto de avaliação de recuperação de informação para português brasileiro produzido na Unicamp. Suas propriedades relevantes:

- Corpus derivado do subconjunto em português do ClueWeb22 Categoria B, em passagens de aproximadamente mil caracteres.
- Duas versões: **1 milhão** e 10 milhões de passagens. Será usada a de 1 milhão, por razões de infraestrutura discutidas na seção 6.
- Consultas formuladas por falantes nativos, e não traduzidas. Foram propostas 200 consultas, das quais **50 possuem qrels** (julgamentos de relevância), com média de 38,66 passagens anotadas por consulta na versão de 1 milhão.
- Anotação de relevância realizada por LLM, com concordância entre anotadores comparável ao desempenho humano segundo os autores.
- Disponível publicamente em huggingface.co/datasets/unicamp-dl/quati, com scripts em github.com/unicamp-dl/quati.

A consequência prática mais importante é que **não há construção de conjunto de avaliação neste trabalho**. Ground truth e scripts de baseline são herdados, o que elimina a fase mais cara e mais arriscada do cronograma e, sobretudo, evita o viés que surgiria se as consultas fossem geradas por LLM a partir dos próprios trechos, prática que favorece sistematicamente a recuperação densa em detrimento da lexical.

3.2 Configurações comparadas

Modelo de embedding fixo (BGE-M3, componente denso, 1024 dimensões), banco vetorial fixo (Qdrant), corpus fixo. Varia-se um único eixo: a precisão de armazenamento dos vetores.

Configuração	Memória de vetores (1M passagens)	Fator	Observação
float32 (linha de base)	≈ 4,10 GB	1×	Precisão simples, sem quantização.
Quantização escalar int8	≈ 1,02 GB	4×	Acrescido de metadados de quantis.
Quantização binária	≈ 128 MB	32×	Um bit por dimensão, distância de Hamming.
Binária com sobreamostragem e reordenação	≈ 128 MB em RAM	32× em RAM	Recupera $k \times$ fator candidatos em binário e reordena com os vetores de precisão simples lidos em disco.

Distinção que o artigo precisa deixar explícita. A quantização binária com reordenação não reduz o armazenamento total, pois exige manter os vetores originais em disco para a etapa de reordenação. O que ela reduz é a memória *residente*. Como o custo operacional real em nuvem é dominado por RAM e não por disco, a métrica economicamente relevante é a memória residente, e é ela que será reportada como eixo principal. Confundir os dois é o erro mais comum na literatura de divulgação sobre o tema, e explicitá-lo é parte da contribuição.

3.3 Métricas

Métrica	Justificativa
nDCG@10	Métrica principal de qualidade, comparável às linhas de base publicadas no artigo original do Quati.
Revocação@100	Relevante para arquiteturas de RAG, em que o estágio de recuperação alimenta um reordenador ou um gerador.
Memória residente (MB)	Medida no processo do Qdrant, não estimada analiticamente.
Latência p95 (ms)	Medida sobre repetições das 50 consultas, com aquecimento descartado.

3.4 Cuidados metodológicos

- **Poder estatístico.** Com apenas 50 consultas anotadas, diferenças pequenas de nDCG não são distinguíveis de ruído. Serão reportados intervalos de confiança por bootstrap e testes pareados entre configurações. Para o int8, o resultado esperado e cientificamente honesto pode ser "nenhuma degradação detectável neste tamanho de amostra", o que é uma conclusão útil e não um fracasso.
- **Latência.** Cinquenta consultas distintas são poucas para um percentil 95 estável. Serão executadas repetições (ordem de 20 por consulta), o que é legítimo porque a medição de latência não requer consultas distintas.
- **Configuração de memória.** Todas as medições de latência devem ocorrer sob a mesma política de residência em memória. Se a configuração float32 for parcialmente mapeada em disco por falta de RAM enquanto a binária cabe integralmente, a comparação de latência perde sentido. Isso condiciona o dimensionamento da máquina descrito na seção 6.
- **Reprodutibilidade.** Sementes fixas, versões de bibliotecas registradas, scripts publicados em repositório.

4. Entregável e contribuição alegada

O artigo entrega uma tabela de compromisso e um gráfico de dispersão qualidade contra memória, com a fronteira de Pareto destacada, encerrando em uma recomendação de ponto de operação para quem monta um índice vetorial em português.

A contribuição alegada é modesta e deliberadamente delimitada: **a primeira medição pública das curvas de degradação por quantização sobre um conjunto de avaliação de recuperação nativo em português brasileiro**. Não se propõe método novo, arquitetura nova nem modelo novo.

5. Limitações

Declaradas aqui de forma antecipada, e a serem repetidas na seção de limitações do artigo.

1. **É um artigo de medição, não de método.** O mérito está no rigor e na utilidade prática, não em novidade conceitual. Isso é adequado ao veículo e não deve ser apresentado como mais do que é.
2. **Cinquenta consultas é pouco.** O poder estatístico limita o que pode ser afirmado. Efeitos grandes, como o da quantização binária sem reordenação, devem ser detectáveis; efeitos pequenos, não.
3. **Os rótulos de relevância do Quati são gerados por LLM.** Os autores demonstram concordância comparável à humana, mas isso não elimina a possibilidade de vieses sistemáticos correlacionados com as próprias famílias de modelos avaliadas.
4. **O corpus é conteúdo web genérico.** Deriva do ClueWeb22 e não representa documentação técnica, jurídica ou administrativa. Conclusões não transferem automaticamente para domínios especializados.
5. **O corpus é predominantemente, mas não exclusivamente, brasileiro.** Amostras do ClueWeb22 em português incluem conteúdo de Portugal. Isso deve ser registrado.
6. **Um único modelo de embedding.** Resultados podem não generalizar para modelos com outra dimensionalidade ou outro regime de treinamento. Um segundo modelo entraria apenas se houver folga de cronograma, o que é improvável.

6. Restrições de infraestrutura e custo

6.1 Hardware necessário

- **GPU** para a passagem de embedding sobre 1 milhão de passagens. Em GPU de consumo com precisão reduzida, a estimativa é de **1 a 4 horas**, dependendo de lote e comprimento efetivo das passagens. É uma passagem única: os vetores são gerados uma vez e reaproveitados em todas as configurações.
- **Memória principal** suficiente para manter a configuração float32 integralmente residente, ou seja, no mínimo 8 GB livres, com 16 GB como alvo confortável. Este é o requisito que **determina o uso da versão de 1 milhão**: a versão de 10 milhões exigiria aproximadamente 41 GB apenas de vetores em precisão simples, o que inviabiliza a medição justa de latência em hardware acessível.
- **Disco** para o corpus, os vetores em precisão simples e os índices. Da ordem de 30 a 50 GB.

6.2 Custo financeiro

Item	Custo	Observação
Conjunto de dados (Quati)	Zero	Público, com licença aberta.
Modelo de embedding (BGE-M3)	Zero	Pesos abertos, execução local.
Banco vetorial (Qdrant)	Zero	Código aberto, execução local em contêiner.
Chamadas a API de LLM	Zero	Nenhuma etapa do experimento depende de modelo comercial.
GPU alugada, se necessário	Abaixo de US\$ 20	Cenário de pior caso: quatro a oito horas de instância com GPU de médio porte. Zero se houver GPU disponível localmente ou em laboratório.

O custo total é, portanto, desprezível. A restrição real deste projeto é tempo, não dinheiro.

7. Restrição de tempo e cronograma

O prazo de submissão encerra em **31/08/2026**. Considerando início imediato, restam aproximadamente 25 dias. O cronograma abaixo pressupõe que a questão de elegibilidade (documento anexo) esteja resolvida nos primeiros dias, em paralelo ao trabalho técnico.

Período	Atividade
Dias 1 a 2	Confirmação de elegibilidade e de orientação. Download do Quati 1M, leitura dos scripts de baseline, reprodução de um número publicado como verificação de sanidade.
Dias 3 a 5	Passagem de embedding sobre o corpus. Persistência dos vetores em precisão simples.
Dias 6 a 9	Construção das quatro configurações de índice no Qdrant. Medição de qualidade, memória e latência.
Dias 10 a 12	Análise estatística, bootstrap, testes pareados. Produção da tabela e do gráfico de Pareto.
Dias 13 a 21	Redação em português no modelo da organização, dentro do limite de 6 páginas. Revisão do orientador.
Dias 22 a 25	Folga. Preparação dos dois PDFs, um identificado e um anonimizado. Cadastro no sistema e submissão.

Ponto de decisão. Se ao fim do dia 9 os números não estiverem produzidos, o projeto não cabe no prazo e deve ser abandonado em favor do eixo de Práticas Docentes, cujo prazo é 08/09. Prefiro registrar esse critério de parada agora, por escrito, a improvisar decisão sob pressão na última semana.

8. Riscos principais

Risco	Mitigação
Elegibilidade não se confirma pelo item 7.2.b	Migrar para Pós-Graduação e Pesquisa (mesmo prazo) ou Práticas Docentes (08/09). Resolver nos dois primeiros dias.
Diferenças entre configurações ficam dentro do ruído	Reportar como ausência de degradação detectável, com intervalos de confiança. É resultado publicável, não fracasso, desde que o poder estatístico seja discutido honestamente.
Indisponibilidade de GPU	Aluguel de instância por poucas horas, custo abaixo de US\$ 20. Alternativa: reduzir o corpus por amostragem, registrando a mudança de escala como limitação.
Seis páginas se mostram insuficientes	Cortar o quarto cenário (binária com reordenação) e manter três configurações. O eixo central da conclusão sobrevive.
Contaminação da medição de latência por falta de RAM	Verificar residência antes de medir e reportar a configuração de memória usada.

9. Alternativas consideradas

- **Comparativo de retrievers em português.** Descartado. Responde "qual modelo é melhor", pergunta cuja resposta muda a cada poucos meses e já é parcialmente respondida pelas linhas de base do próprio Quati.
- **Curva de custo e benefício da reordenação por cross-encoder.** Variar a profundidade de candidatos enviados ao reordenador e medir ganho de nDCG contra custo de latência. Igualmente viável, mesmo arcabouço experimental, mesma forma de resultado. Substituto direto caso o eixo de quantização se mostre inviável.
- **Confiabilidade de saída estruturada em modelos abertos pequenos.** Descartado deliberadamente. O tema tangencia decodificação restrita, que é matéria de trabalhos futuros do meu TCC, e publicar medições sobre ele agora comprometeria aquele enquadramento.

10. Referências principais

1. OLIVEIRA, E. de; BUENO, M.; NOGUEIRA, R.; LOTUFO, R.; PEREIRA, J. Quati: A Brazilian Portuguese Information Retrieval Dataset from Native Speakers. In: *Proceedings of the 15th Brazilian Symposium in Information and Human Language Technology (STIL 2024)*, Belém do Pará, p. 185-195.

2. OVERWIJK, A. et al. ClueWeb22: 10 Billion Web Documents with Rich Information. 2022. Corpus de origem das passagens do Quati.
3. BONIFACIO, L. et al. mMARCO: A Multilingual Version of the MS MARCO Passage Ranking Dataset. Referência para a discussão sobre limitações de datasets traduzidos.
4. CHEN, J. et al. BGE M3-Embedding: Multi-Lingual, Multi-Functionality, Multi-Granularity Text Embeddings Through Self-Knowledge Distillation. Modelo de embedding adotado.
5. Documentação técnica do Qdrant sobre quantização escalar e binária, e sobre sobreamostragem com reordenação.

As estimativas de memória são analíticas (número de passagens multiplicado pela dimensionalidade e pela largura do tipo) e serão substituídas por medições diretas no artigo. As estimativas de tempo de embedding são ordens de grandeza e dependem do hardware efetivamente disponível.